MovieLens_clusterization

April 28, 2019

```
In [5]: %install_ext https://raw.github.com/cpcloud/ipython-autotime/master/autotime.py
        %load_ext autotime
```

```
UsageError: Line magic function `%install_ext` not found.
```

```
In [778]: import mlxtend
          import numpy as np
          import pandas as pd
          import re

          from mpl_toolkits.mplot3d import Axes3D
          import matplotlib.pyplot as plt
          import pandas as pd
          import seaborn as sns

          import time
          from functools import wraps

          from scipy import stats

          from sklearn.cluster import KMeans, DBSCAN
          from sklearn.cluster import k_means_

          from sklearn.metrics.pairwise import euclidean_distances, cosine_similarity, cosine_

          from sklearn.decomposition import PCA

          from sklearn.model_selection import learning_curve
          from sklearn.preprocessing import StandardScaler  # For scaling dataset
          from sklearn.metrics import silhouette_score
          import seaborn as sns; sns.set(style="ticks", color_codes=True)
```

1 Resumo

O objetivo deste notbook é executar o trablho da disciplina de Data Mining I. O enunciado pedia que:

- Encontrássemos clusters de filmes semelhantes usando as notas dadas pelos usuários como features do modelo.
- Para lidar com o grande número de dimensões dos vetores de features, deveríamos usar uma transformada PCA para reduzir a dimensão do prodlema.
- Utilizar os algoritmos: KMeans e DBScan para gerar os clusters

A bases de 100k e 1M já haviam sido tratadas no trabalho anterior, por isso nenhum pré-processamento de limpeza dos dados foi feito. A ordem do Notebbok, seguiu o processo de experimentação realmente executado. Caso apenas as conclusões sejam de interesse, a sessão de conclusão resume o que foi encontrado.

2 Importando o dataset

dataset depois do tratamento feito para a análise de Market Basket.

```
In [779]: ratingsDF = pd.read_pickle("..\\ProcessedData\\df.pkl")

In [780]: ratingsDF.head()
```

Out[780]:

	uid	id	rating	timestamp	movie_title	release_date	\
0	196	242	3	1997-12-04 15:55:49	Kolya (1996)	1997-01-24	
1	63	242	3	1997-10-01 23:06:30	Kolya (1996)	1997-01-24	
2	226	242	5	1998-01-04 04:37:51	Kolya (1996)	1997-01-24	
3	154	242	3	1997-11-10 05:03:55	Kolya (1996)	1997-01-24	
4	306	242	5	1997-10-10 17:16:33	Kolya (1996)	1997-01-24	

	IMDb_URL	unknown	Action	Adventure	\
0	http://us.imdb.com/M/title-exact?Kolya%20(1996)	0	0	0	
1	http://us.imdb.com/M/title-exact?Kolya%20(1996)	0	0	0	
2	http://us.imdb.com/M/title-exact?Kolya%20(1996)	0	0	0	
3	http://us.imdb.com/M/title-exact?Kolya%20(1996)	0	0	0	
4	http://us.imdb.com/M/title-exact?Kolya%20(1996)	0	0	0	

	...	Fantasy	Film-Noir	Horror	Musical	Mystery	Romance	Sci-Fi	Thriller	\
0	...	0	0	0	0	0	0	0	0	
1	...	0	0	0	0	0	0	0	0	
2	...	0	0	0	0	0	0	0	0	
3	...	0	0	0	0	0	0	0	0	
4	...	0	0	0	0	0	0	0	0	

	War	Western
0	0	0
1	0	0
2	0	0
3	0	0
4	0	0

[5 rows x 26 columns]

```
In [781]: print("Número de usuários na base %i" % ratingsDF['uid'].nunique())

Número de usuários na base 943


In [782]: print("Número de filmes na base %i" % ratingsDF['id'].nunique())

Número de filmes na base 1664
```

2.1 Criando os vetores de features dos filmes

Cada filme será representado pelas notas que cada um dos usuários da base deu para aquele filme. O que siginifica que **cada filme será representado por vetores esparsos de tamanho 943**.

Sabemos da exploração que não há duplicatas para a chave **uid, id**, então:

```
In [783]: ratings_id = ratingsDF.groupby(['id']).aggregate({'rating': len})

In [784]: plt.figure(),
          plt.subplot(1,2,1)
          ratings_id.rating.hist()
          plt.grid(True)
          plt.title("#usuários que viram o filme")
          plt.xlabel("uid")
          plt.ylabel("freq absoluta")

          plt.subplot(1,2,2)
          ratings_id.boxplot()
          plt.title("Boxplot que viram o filme")
          plt.rcParams['figure.figsize'] = (11,7)
          plt.show()
```

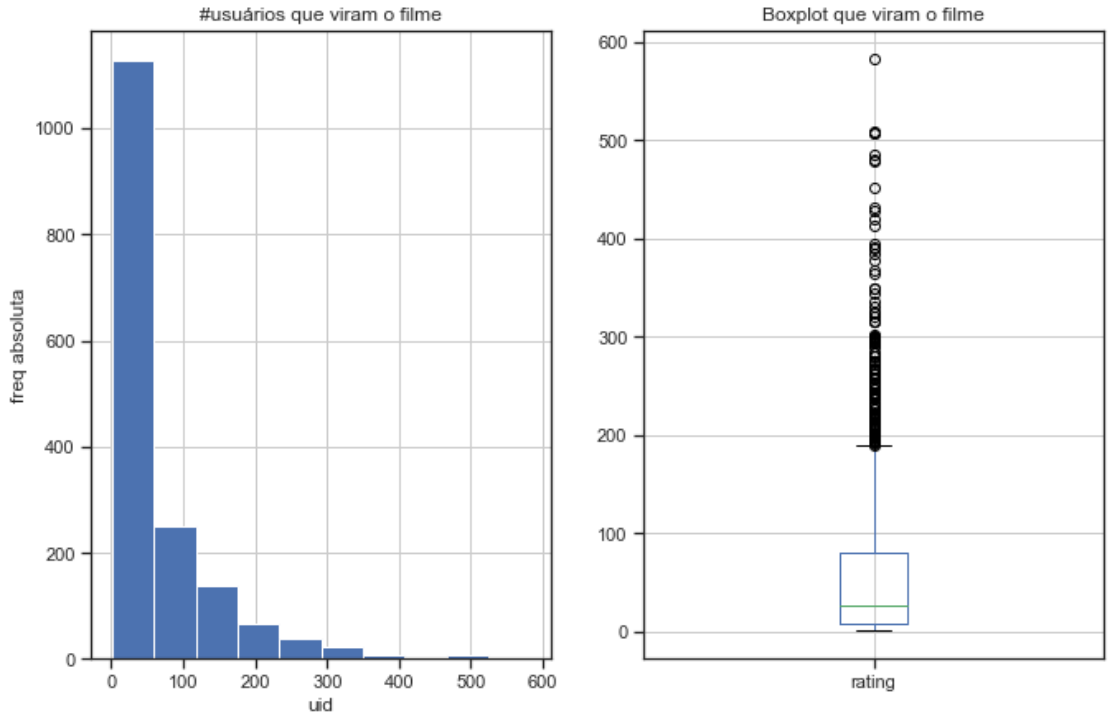


```
In [785]: print("Moda do número de usuários que viram o filme: %i" % ratings_id.rating.mode())
          print("Média do número de usuários que viram o filme: %i" % ratings_id.rating.mean())
```

```
Moda do número de usuários que viram o filme: 1
Média do número de usuários que viram o filme: 59
```

```
In [786]: print("Número de filmes com apenas uma avaliação: %i" % (ratings_id.rating == 1).sum
```

```
Número de filmes com apenas uma avaliação: 135
```

2.2 Filmes mais vistos

Para depois achar quais so clusters dos filmes mais populares. Vou definer como sendo um filme muito visto aquele com mais de 150 usuários damdp mota diferente de 0

```
In [787]: popular_film = (ratings_id.rating > 150)
```

```
In [788]: print("número de filmes populares %i" % popular_film.sum())
```

```
número de filmes populares 202
```

```
In [789]: popular_ids = popular_film[popular_film]
```

abaixo uma amostra das notas dadas aos filmes populares

```
In [790]: ratingsDF[ratingsDF['id'].isin(popular_ids.index)].sample(10)
```

```
Out[790]:        uid   id rating           timestamp  \
          76166  193  282      5 1998-03-05 19:09:25
          62702  788  230      3 1997-11-30 06:02:34
          51056  182   50      5 1998-01-24 03:36:58
          76697  113  300      3 1997-09-24 04:38:07
          30038  910  127      5 1997-11-29 16:47:40
          8309   791  322      4 1997-11-13 19:08:48
          25343   79  258      5 1998-03-30 15:21:48
          67664  184  393      4 1998-03-14 21:09:48
          16002  508  208      5 1998-01-02 21:32:28
          11156  230  427      5 1997-11-25 19:01:41

                                        movie_title release_date  \
          76166                Time to Kill, A (1996)   1996-07-13
          62702  Star Trek IV: The Voyage Home (1986)   1986-01-01
          51056                      Star Wars (1977)   1977-01-01
          76697                   Air Force One (1997)   1997-01-01
          30038                 Godfather, The (1972)   1972-01-01
          8309                  Murder at 1600 (1997)   1997-04-18
          25343                        Contact (1997)   1997-07-11
          67664                 Mrs. Doubtfire (1993)   1993-01-01
          16002             Young Frankenstein (1974)   1974-01-01
          11156          To Kill a Mockingbird (1962)   1962-01-01

                                                  IMDb_URL unknown Action  \
          76166  http://us.imdb.com/M/title-exact?Time%20to%20K...       0      0
          62702  http://us.imdb.com/M/title-exact?Star%20Trek%2...       0      1
          51056  http://us.imdb.com/M/title-exact?Star%20Wars%2...       0      1
          76697  http://us.imdb.com/M/title-exact?Air+Force+One...       0      1
          30038  http://us.imdb.com/M/title-exact?Godfather,%20...       0      1
          8309   http://us.imdb.com/M/title-exact?Murder%20at%2...       0      0
          25343          http://us.imdb.com/Title?Contact+(1997/I)       0      0
          67664  http://us.imdb.com/M/title-exact?Mrs.%20Doubtf...       0      0
          16002  http://us.imdb.com/M/title-exact?Young%20Frank...       0      0
          11156  http://us.imdb.com/M/title-exact?To%20Kill%20a...       0      0

                Adventure   ...   Fantasy Film-Noir Horror Musical Mystery Romance  \
          76166         0   ...         0         0      0       0       0       0
          62702         1   ...         0         0      0       0       0       0
          51056         1   ...         0         0      0       0       0       1
          76697         0   ...         0         0      0       0       0       0
          30038         0   ...         0         0      0       0       0       0
          8309          0   ...         0         0      0       0       1       0
          25343         0   ...         0         0      0       0       0       0
```

```
67664         0   ...         0         0      0       0       0       0
16002         0   ...         0         0      1       0       0       0
11156         0   ...         0         0      0       0       0       0

      Sci-Fi Thriller War Western
76166      0        0   0       0
62702      1        0   0       0
51056      1        0   1       0
76697      0        1   0       0
30038      0        0   0       0
8309       0        1   0       0
25343      1        0   0       0
67664      0        0   0       0
16002      0        0   0       0
11156      0        0   0       0

[10 rows x 26 columns]
```

3 Criando a versão pivoteada do dataset

```
In [791]: def collapse_columns(df):
              df = df.copy()
              if isinstance(df.columns, pd.MultiIndex):
                  df.columns = df.columns.to_series().str.join('')
              return df

In [792]: %%time
          df_pivoted = pd.pivot_table(ratingsDF, columns=['uid'], values=['rating'], index=['i

Wall time: 1min 16s


In [793]: # df_pivoted.fillna(0, inplace=True)

In [794]: df_flattern = df_pivoted.copy()
          df_flattern.columns = df_pivoted.columns.get_level_values(1)

In [795]: df_flattern.head(10)

Out[795]: uid  1    2    3    4    5    6    7    8    9    10  ...   934  935  936  \
          id                                                    ...
          1    5.0  4.0  NaN  NaN  4.0  4.0  NaN  NaN  NaN  4.0 ...   2.0  3.0  4.0
          2    3.0  NaN  NaN  NaN  3.0  NaN  NaN  NaN  NaN  NaN ...   4.0  NaN  NaN
          3    4.0  NaN  NaN  NaN  NaN  NaN  NaN  NaN  NaN  NaN ...   NaN  NaN  4.0
          4    3.0  NaN  NaN  NaN  NaN  NaN  5.0  NaN  NaN  4.0 ...   5.0  NaN  NaN
          5    3.0  NaN  NaN  NaN  NaN  NaN  NaN  NaN  NaN  NaN ...   NaN  NaN  NaN
          6    5.0  NaN  NaN  NaN  NaN  NaN  NaN  NaN  5.0  NaN ...   NaN  NaN  5.0
          7    4.0  NaN  NaN  NaN  NaN  2.0  5.0  3.0  4.0  4.0 ...   NaN  NaN  4.0
```

```
8    1.0  NaN  NaN  NaN  NaN  4.0  5.0  NaN  NaN  NaN ...   NaN  NaN  NaN
9    5.0  NaN  NaN  NaN  NaN  4.0  5.0  NaN  NaN  4.0 ...   NaN  1.0  4.0
10   3.0  2.0  NaN  NaN  NaN  NaN  4.0  NaN  NaN  NaN ...   NaN  NaN  NaN

uid  937  938  939  940  941  942  943
id
1    NaN  4.0  NaN  NaN  5.0  NaN  NaN
2    NaN  NaN  NaN  NaN  NaN  NaN  5.0
3    NaN  NaN  NaN  NaN  NaN  NaN  NaN
4    NaN  NaN  NaN  2.0  NaN  NaN  NaN
5    NaN  NaN  NaN  NaN  NaN  NaN  NaN
6    NaN  NaN  NaN  NaN  NaN  NaN  NaN
7    NaN  4.0  NaN  4.0  4.0  NaN  NaN
8    NaN  NaN  NaN  5.0  NaN  NaN  NaN
9    5.0  3.0  5.0  3.0  NaN  NaN  3.0
10   NaN  NaN  NaN  NaN  NaN  NaN  NaN

[10 rows x 943 columns]
```

3.1 Formato Esparso do dataset

o dataset pode ser codificado de forma esparsa antes do fill de NaN pelas médias, talvez gere ganho

```
In [796]: df_pivoted_spase = df_flattern.to_sparse()
```

3.2 Fill de valores nulos

Os algoritimos que vamos utilizar são sensíveis aos valores nulos. Para diminuir esse efeito, podemos substituir zeros pela média das notas dos filmes desconsiderando os valores 0 (que são NAN na verdade);

```
In [797]: filmMeanRating = df_pivoted.mean(axis=1)
```

> Obs: a função fill na por linha não está implementada no Pandas, por isso as transposições

```
In [798]: df_flattern = df_flattern.T.fillna(filmMeanRating).T

In [799]: df_flattern.T.describe()

Out[799]: id            1           2           3           4           5           6     \
          count  943.000000  943.000000  943.000000  943.000000  943.000000  943.000000
          mean     3.878319    3.206107    3.033333    3.550239    3.302326    3.576923
          std      0.642041    0.359043    0.372773    0.453487    0.284302    0.212022
          min      1.000000    1.000000    1.000000    1.000000    1.000000    1.000000
          25%      3.878319    3.206107    3.033333    3.550239    3.302326    3.576923
          50%      3.878319    3.206107    3.033333    3.550239    3.302326    3.576923
          75%      4.000000    3.206107    3.033333    3.550239    3.302326    3.576923
```

```
max      5.000000    5.000000    5.000000    5.000000    5.000000    5.000000

id           7           8           9          10    ...     1672   1673  \
count  943.000000  943.000000  943.000000  943.000000  ...    943.0  943.0
mean     3.798469    3.995434    3.896321    3.831461  ...      2.0    3.0
std      0.632690    0.482161    0.586278    0.309907  ...      0.0    0.0
min      1.000000    1.000000    1.000000    1.000000  ...      2.0    3.0
25%      3.798469    3.995434    3.896321    3.831461  ...      2.0    3.0
50%      3.798469    3.995434    3.896321    3.831461  ...      2.0    3.0
75%      4.000000    3.995434    3.896321    3.831461  ...      2.0    3.0
max      5.000000    5.000000    5.000000    5.000000  ...      2.0    3.0

id      1674   1675   1676   1677   1678   1679   1681   1682
count  943.0  943.0  943.0  943.0  943.0  943.0  943.0  943.0
mean     4.0    3.0    2.0    3.0    1.0    3.0    3.0    3.0
std      0.0    0.0    0.0    0.0    0.0    0.0    0.0    0.0
min      4.0    3.0    2.0    3.0    1.0    3.0    3.0    3.0
25%      4.0    3.0    2.0    3.0    1.0    3.0    3.0    3.0
50%      4.0    3.0    2.0    3.0    1.0    3.0    3.0    3.0
75%      4.0    3.0    2.0    3.0    1.0    3.0    3.0    3.0
max      4.0    3.0    2.0    3.0    1.0    3.0    3.0    3.0

[8 rows x 1664 columns]
```

```
In [800]: df_flattern.to_pickle('films_features.pkl')
```

4 Decomposição do vetor de features

4.1 PCA

```
In [801]: pca_dim = 943
```

```
In [802]: pca = PCA(n_components=pca_dim).fit(df_flattern)
```

```
In [803]: cumulativeVar = pd.Series(pca.explained_variance_ratio_.cumsum())
```

```
In [804]: plt.figure(),
          cumulativeVar.plot()
          plt.grid(True)
          plt.title("soma cumulativa das variâncias")
          plt.xlabel("#PCA components")
          plt.ylabel("cum. sum.")
          plt.show()
```

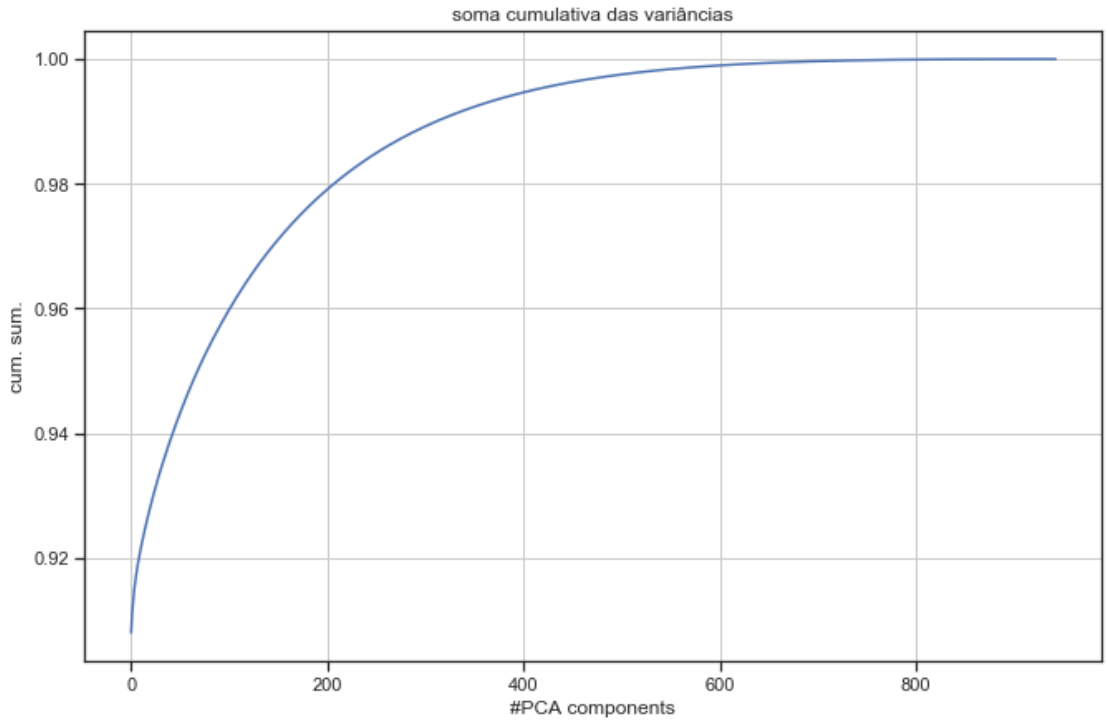

a variância ao longo das 5 primeiras dimensões já é da ordem de **e-5**. Se reduzirmos o número de dimensões para apenas 2 temos:

```
In [805]: pca_dim = 3
          pca = PCA(n_components=pca_dim).fit(df_flattern)

In [806]: print("energia conservada pelas %i primeiras componentes do PCA %f" % (pca_dim, pca.e

energia conservada pelas 3 primeiras componentes do PCA 0.912999


In [807]: df_pca = pd.DataFrame(pca.transform(df_flattern))
```

Data Scatter

```
In [808]: # plt.figure().gca(projection='3d')
          plt.figure()
          # plt.scatter(df_pca[0], df_pca[1], df_pca[2])
          plt.scatter(df_pca[0], df_pca[1])
          plt.grid(True)
          plt.title("filmes")
          plt.xlabel("pca_0")
          plt.ylabel("pca_1")
          plt.show()
```

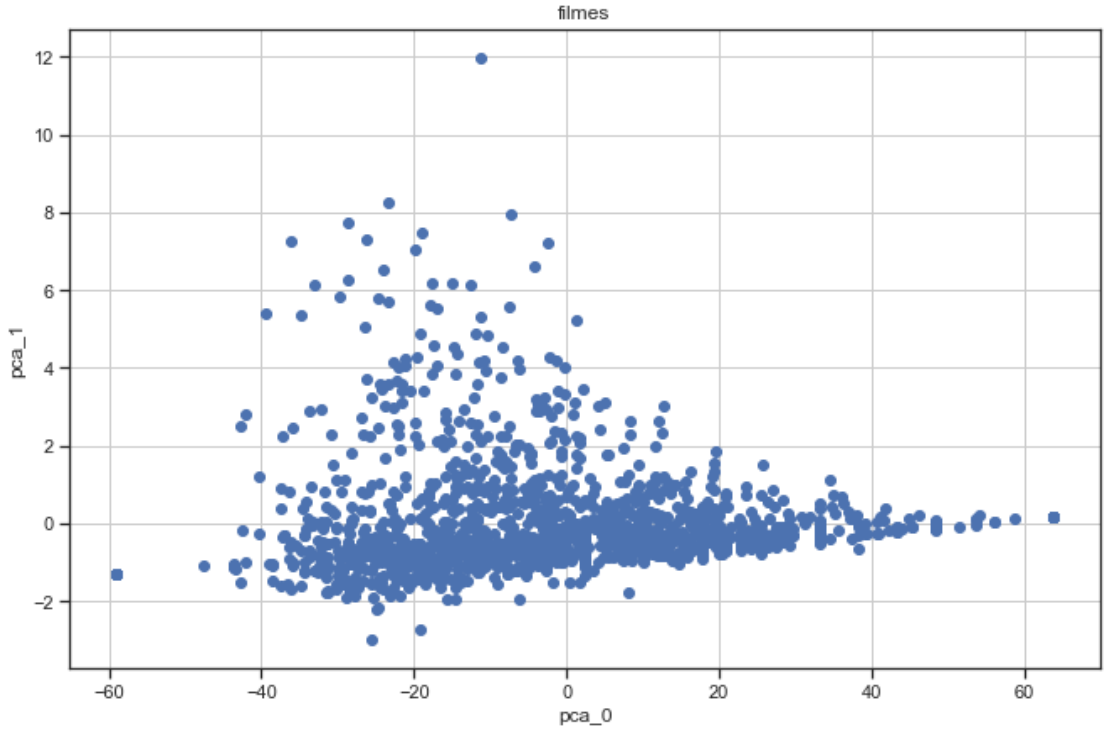

5 Clusterização

Posdemos executar a clusterização no espaço não transformado pelo PCA enquanto isso não gerar problemas de desempenho. Pode-se usar o PCA para fazer a projeção para 2D e faciliar a visualização dos clustes

```
In [809]: # %%time
          # plot_learning_curve(
          #     estimator=kmeans, # clustering algorithm
          #     X=df_pivoted,y=None, # None for unsupervisioned
          #     train_sizes=(1.0,), # all for training
          #     cv=10, #cross-validation maninfolds
          #     title="kmeans learning"
          # )
```

5.1 Kmeans usando a norma L2 como medida de dessimilaridade

Primeiro devemos determinar o número de clusters

5.1.1 Treinamento

Para determinar o número de clusters, procuramos por um joelho na gráfico de loss (norma L@) vs número de clusters

```
In [ ]: th_min = 0
        th_max = 2
        n_clusters_range = np.rint(np.logspace(th_min,th_max,num=30))

In [ ]: scores = []
        time_elapsed = []

In [ ]: df_for_clustering = df_pca

In [ ]: %%time
        for n in n_clusters_range:
            start_time = time.time()
            kmeans = KMeans(n_clusters=int(n)).fit(df_for_clustering)
            elapsed_time = time.time() - start_time
            scores.append(kmeans.inertia_)
            time_elapsed.append(elapsed_time)

Wall time: 4.7 s
```

A inércia dividida pelo número de pontos na base dá a noção da distância média entre os pontos e seus clusters, que é uma quantidade mais intuitiva

```
In [ ]: scores = np.array(scores)/len(df_for_clustering)

In [ ]: plt.figure(),
        plt.subplot(2,1,1)
        plt.plot( n_clusters_range, scores)
        plt.grid(True)
        plt.title("score x #clusters")
        plt.ylabel("score")
        plt.subplot(2,1,2)
        plt.plot( n_clusters_range, time_elapsed)
        plt.grid(True)
        plt.xlabel("#clusters")
        plt.ylabel("time_elapsed")
        plt.show()
```

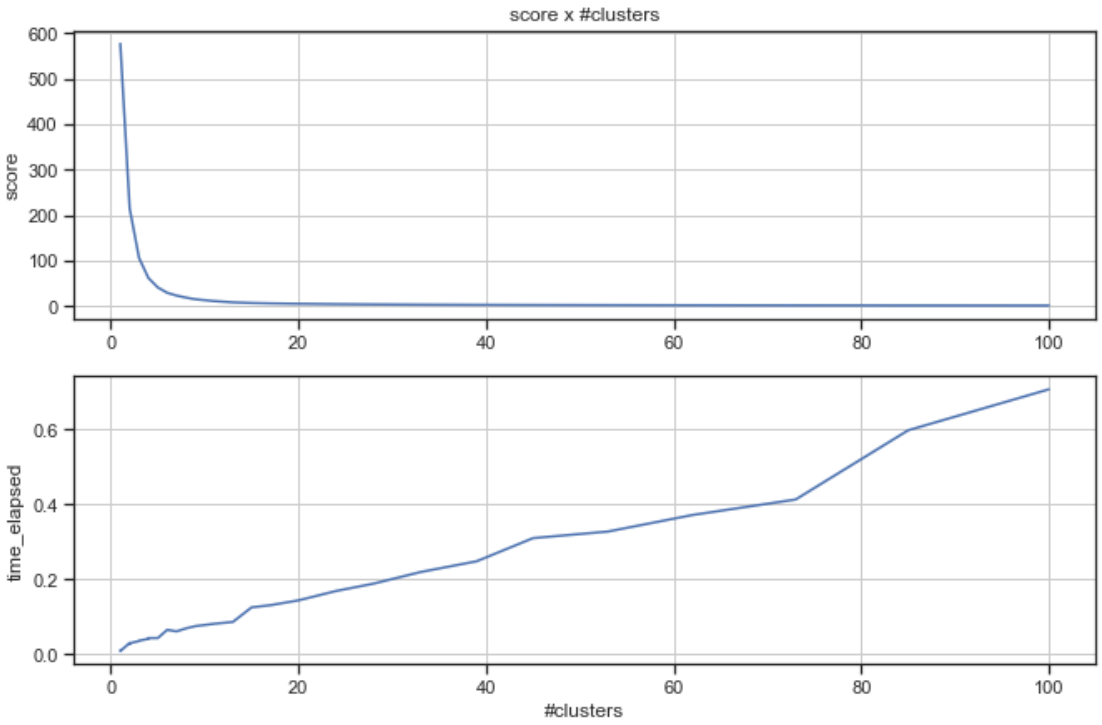


```
In [ ]: #Scaling of data
        # ss = StandardScaler()
        # ss.fit_transform(df_pivoted_sparse)

        clust_labels = kmeans.labels_
```

Por inspeção, há um joelho entre 10 e 20, vou repetir a análise para aumentar o range de 10 a 20

```
In [ ]: n_clusters_range2 = np.linspace(5,20,num=10)
```

```
In [ ]: scores2 = []
        time_elapsed2 = []
```

```
In [ ]: %%time
        for n in n_clusters_range2:
            start_time = time.time()
            kmeans = KMeans(n_clusters=int(n)).fit(df_for_clustering)
            elapsed_time = time.time() - start_time
            scores2.append(kmeans.inertia_)
            time_elapsed2.append(elapsed_time)

Wall time: 966 ms
```

A inércia dividida pelo número de pontos na base dá a noção da distância média entre os pontos e seus clusters, que é uma quantidade mais intuitiva

```
In [ ]: scores2 = np.array(scores2)/len(df_for_clustering)
```

```
In [ ]: plt.figure(),
        plt.subplot(2,1,1)
        plt.plot( n_clusters_range2, scores2)
        plt.grid(True)
        plt.title("score x #clusters")
        plt.ylabel("score")
        plt.subplot(2,1,2)
        plt.plot( n_clusters_range2, time_elapsed2)
        plt.grid(True)
        plt.xlabel("#clusters")
        plt.ylabel("time_elapsed")
        plt.show()
```

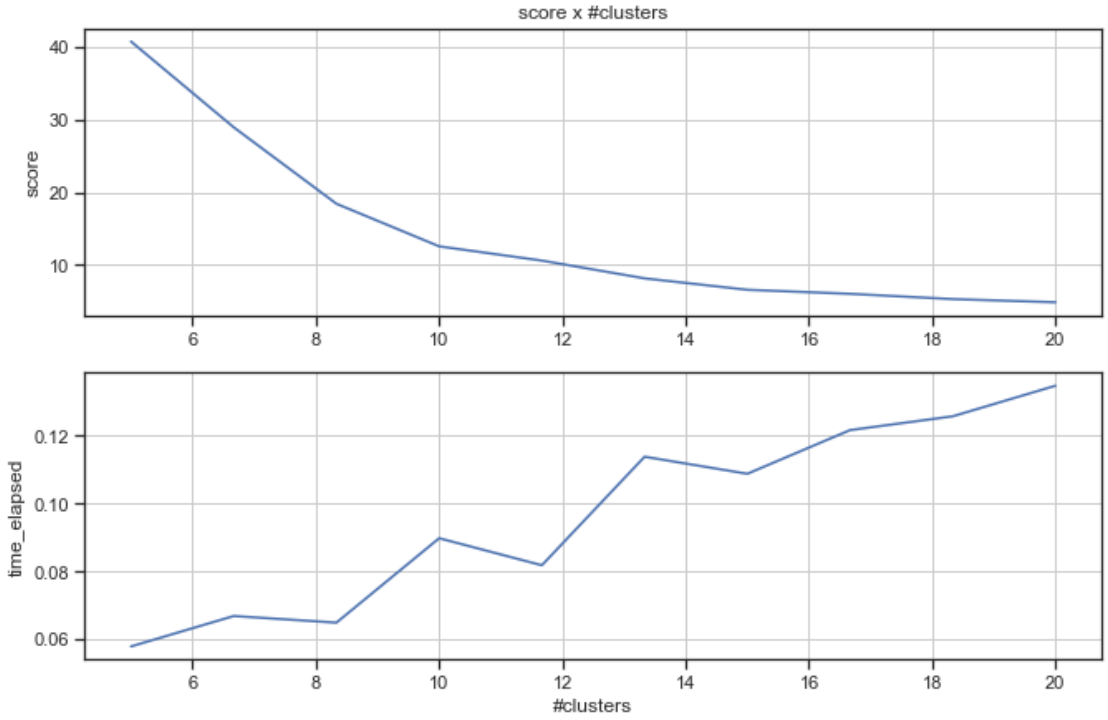

Por inspeção n=10, parece uma boa definição para o joelho

```
In [ ]: n_ = 10
        kmeans = KMeans(n_clusters=n_).fit(df_for_clustering)
```

```
In [ ]: clust_labels = kmeans.labels_
```

```
In [ ]: df = df_for_clustering.copy()
        df['cluster'] = clust_labels
```

```
In [ ]: filmsInClusterCount = pd.Series(data=df.groupby(['cluster']).count()[0])
        plt.figure(),
        filmsInClusterCount.plot.bar(x='index', y='cluster', rot=0)
        plt.xlabel("cluster")
        plt.grid(True)
        plt.ylabel("freq. absoluta")
        plt.title('distribuição nos clusters')
        plt.show()
```

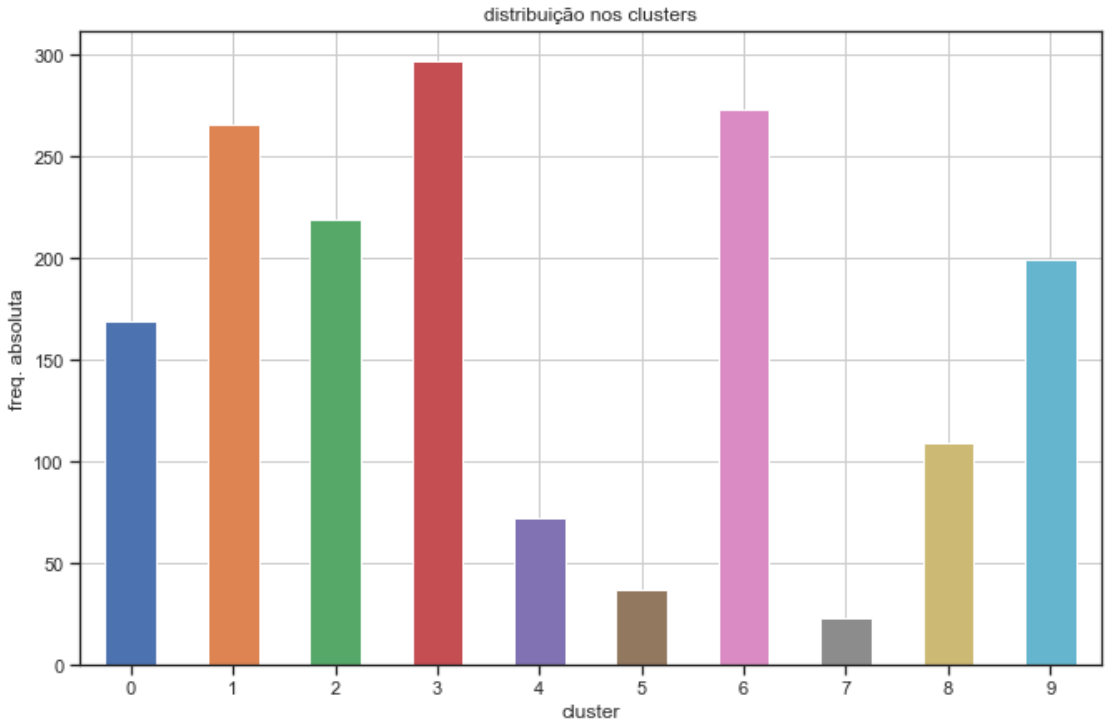

5.1.2 Visualizando so resultados

com os clusters treinados, podemos prosseguir com a análise e tentar descobrir se são relevantes

```
In [ ]: plt.figure(),
        g = sns.pairplot( df, hue="cluster", x_vars=df_pca.columns, y_vars=df_pca.columns)
        plt.show()
```

```
C:\Users\souza\Anaconda3\envs\movielens_env\lib\site-packages\scipy\stats\stats.py:1713: Future
  return np.add.reduce(sorted[indexer] * weights, axis=axis) / sumval


<Figure size 792x504 with 0 Axes>
```

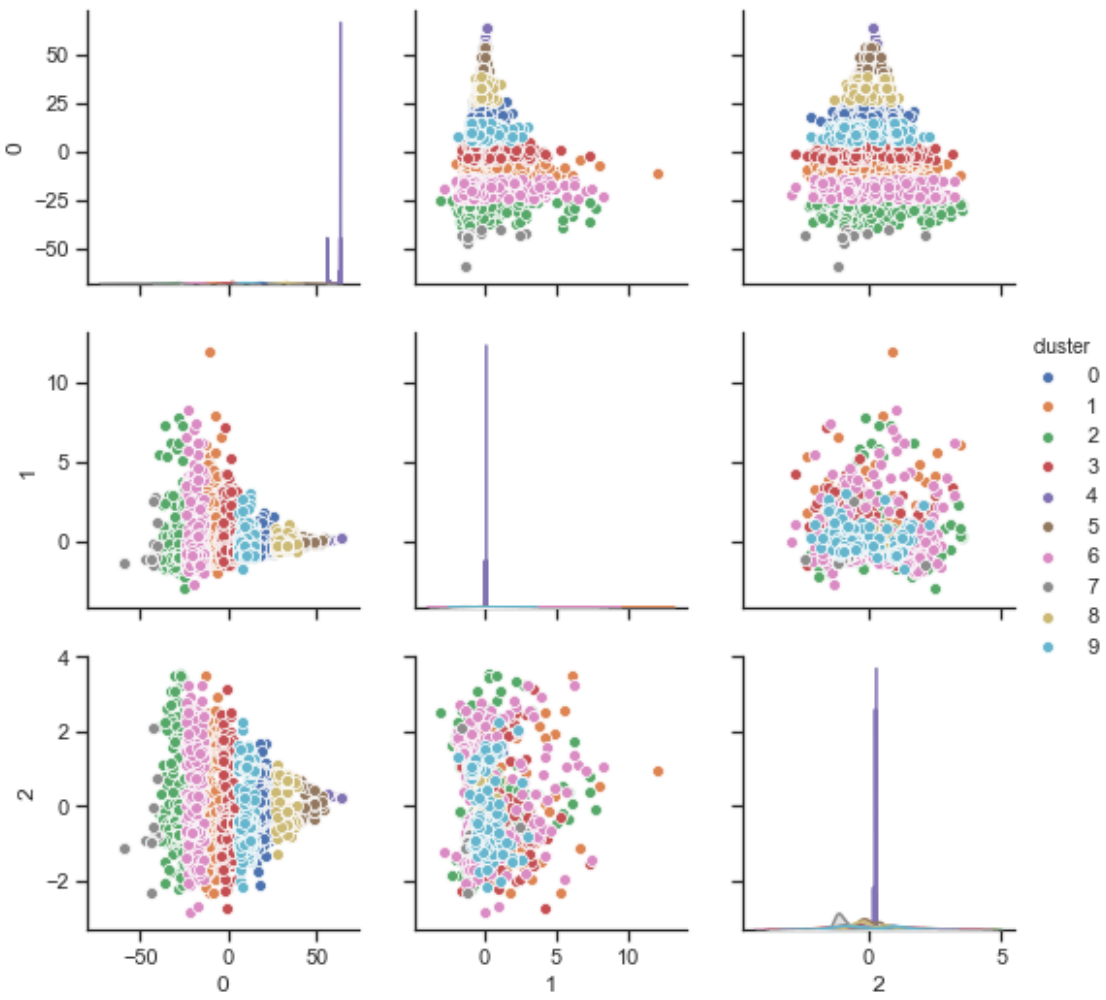

Conclusões

Aparentemente, os clusters usados separaram os dados (para a maioria dos clusters), com planos ortogonais ao eixo 0 do PCA.

```
In [ ]: to_enrich = ratingsDF.groupby('id').agg(
            {'timestamp':'first',
             'id':'first',
             'movie_title':'first',
             'release_date':'first',
             'unknown':'first',
             'Action':'first',
             'Adventure':'first',
             'Animation':'first',
             'Children\'s':'first',
              'Comedy':'first',
```

```
            'Crime':'first',
            'Documentary':'first',
            'Drama':'first',
            'Fantasy':'first',
            'Film-Noir':'first',
              'Horror':'first',
            'Musical':'first',
            'Mystery':'first',
            'Romance':'first',
            'Sci-Fi':'first',
            'Thriller':'first',
            'War':'first',
           'Western':'first'
           })
```

```
In [ ]: df_full = pd.concat([df, to_enrich], axis=1, join='inner')
```

```
In [ ]: df_full[df_full['cluster'] == 0].head(10)
        df_full = df_full.rename(mapper={0:'pca_0', 1:'pca_1', 2:'pca_2'}, axis='columns')
```

```
In [ ]: df_full.head(10)
```

Intra cluster coesion

```
In [ ]: intra_cluster_dist = []
        dists_sum = []
        for c in range(0, n_):
            in_cluster = df_full[df_full.cluster == c]
            centroid = np.array(kmeans.cluster_centers_[c]).reshape(1,-1)
            dists = euclidean_distances(in_cluster[["pca_0","pca_1","pca_2"]], centroid)
            sqr = np.dot(dists.reshape(-1),dists.reshape(-1))
            dists_sum.append(sqr)
            dist = dists.mean()
            cluster_sz = len(in_cluster)
            intra_cluster_dist.append([c,dist,cluster_sz])
        intra_cluster_dist = pd.DataFrame(columns=['cluster', 'mean_dist', 'cluster_sz'], data=
```

Os clusters em ordem de coesão

```
In [ ]: intra_cluster_dist.sort_values(['mean_dist'])
```

Conclusão > os clusters 9 e 7 são pequenos e pouco coesos, o que pode significar que não sejam clusters de fato, mas apenas 'outliers'

```
In [ ]: for c in range(0, n_):
            in_cluster = df_full[df_full.cluster == c]
            print("Cluster %i" % c)
            print(in_cluster.sample(n=10)['movie_title'])
            in_cluster.to_csv("../ProcessedData/clustering/10k/cluster_%i_kmeans.csv" % c)
            clusters_samples[c] = in_cluster
```

5.1.3 Onde estão os filmes populares?

```
In [ ]: kmeans_populares = df_full[df_full['id'].isin(popular_ids.index)]

In [ ]: filmsInClusterCount = pd.Series(data=kmeans_populares.groupby(['cluster']).count()['pca

In [ ]: plt.figure()
        filmsInClusterCount.plot.bar()
        plt.xlabel("cluster")
        plt.grid(True)
        plt.ylabel("freq. absoluta")
        plt.title('distribuição dos filmes populares nos clusters')
        plt.show()
```

conclsão > Hà filmes populares em todos os clusters, mas são mais frequentes nos clusters 0, 2, 5 e 8

```
In [ ]: for c in range(0, n_):
            in_cluster = kmeans_populares[kmeans_populares.cluster == c]
            if len(in_cluster)> 2:
                print("filmes populares do Cluster %i" % c)
                print(in_cluster.sample(n=2)['movie_title'])
                in_cluster.to_csv("../ProcessedData/clustering/10k/cluster_%i_kmeans.csv" % c)
                clusters_samples[c] = in_cluster
```

5.2 DBScan usando a norma L2 como medida de dessimilaridade

Primeiro devemos determinar os hiperparâmetros 1. **eps**: The maximum distance between two samples for them to be considered as in the same neighborhood. 2. **min_samples**: The number of samples (or total weight) in a neighborhood for a point to be considered as a core point. This includes the point itself.

5.2.1 range de EPS

Vou me basear nos valores típicos de distâncias no dataset

```
In [ ]: dists = pd.Series(euclidean_distances(df_for_clustering, df_for_clustering).reshape(-1)

In [ ]: plt.figure()
        pd.Series(dists).hist()
        plt.title('distribuição das distâncias entre pontos')
        plt.xlabel('distância')
        plt.ylabel('freqq. absoluta')
        plt.show()

In [ ]: dists.describe()
```

Conclusão > vou fazer esse parâmetro variar dentro do primeiro quartil, ou seja, entre 0 e 10

5.2.2 Treinamento

```
In [ ]: def clustering_score(clustering, df):
            dists_sum = []
            intra_cluster_dist = []
            cluster_sz = []
            labels = pd.Series(clustering.labels_)
            n_ = labels.max() + 1
            for c in range(0, n_):
                in_cluster = df.iloc[clustering.labels_ == c]
                centroid = np.array(clustering.cluster_centers_[c]).reshape(1,-1)
                dists = euclidean_distances(df, centroid)
                dist = dists.mean()
                dists_sum.append(dists.sum())
                cluster_sz = len(in_cluster)
                intra_cluster_dist.append([c,dist,cluster_sz])
            intra_cluster_dist = pd.DataFrame(columns=['cluster', 'mean_dist', 'cluster_sz'], c
            inertia = np.array(dists_sum).sum()
            return intra_cluster_dist, inertia

In [ ]: eps_range = np.logspace(-2,1,num=30)
        min_sample_range = np.rint(np.linspace(1,10,num=10))
```

Exemplo fornecido pela documentação do SKlearn da classse DBSCAN

```
from sklearn.cluster import DBSCAN
import numpy as np
X = np.array([[1, 2], [2, 2], [2, 3],
              [8, 7], [8, 8], [25, 80]])
clustering = DBSCAN(eps=3, min_samples=2).fit(X)
clustering.labels_
```

```
In [ ]: from sklearn.cluster import DBSCAN
        import numpy as np
        dbscan = DBSCAN(eps=.9, min_samples=6).fit(df_for_clustering)

In [ ]: n_clusters = labels
        df_clustered = df_for_clustering.copy()
        df_clustered['cluster'] = dbscan.labels_

In [ ]: # dosts, intertia = clustering_score(clustering,df_for_clustering )

In [ ]: # %%time
        # time_elapsed = []
        # scores = []
        # for n in eps_range:
        #     for m in min_sample_range:
        #         start_time = time.time()
        #         dbscan = DBSCAN(eps=n, min_samples=m).fit(df_for_clustering)
```

```
        #         elapsed_time = time.time() - start_time
        #         dosts, intertia = clustering_score(dbscan,df_for_clustering )
        #         scores.append(intertia)
        #         time_elapsed.append(elapsed_time)
```

```
In [ ]: plt.figure()
        g = sns.pairplot( df_clustered, hue="cluster", x_vars=df_for_clustering.columns, y_vars
        plt.show()
```

```
In [ ]: filmsInClusterCount = pd.Series(data=df_clustered.groupby(['cluster']).count()[0])
```

```
In [ ]: plt.figure(),
        filmsInClusterCount.plot.bar(x='index', y='cluster', rot=0)
        plt.xlabel("cluster")
        plt.grid(True)
        plt.ylabel("freq. absoluta")
        plt.title('distribuição nos clusters')
        plt.show()
```

Conclusão > A ausência do centroide dificulta um pouco a avaliação do que seria a coesão intra-cluster. > Após algumas tentativas varrendo manualmente os parâmetros do algorítimo, achei que os clusters acima eram significativos em termos de número de filmes no cluster. Observei que: > > * Se diminuimos o eps, mantendo-se o mesmo valor de min_samples, o grupo 0 aumenta e o grupo -1 (ruído) diminui > * Se mantemos o valor de eps fixo e aumentamos o valor de min_samples, o número de clusters diminui e o tamanho do grupo -1 (ruído) também aumenta.

5.2.3 Visualizando so resultados

```
In [ ]: df_full2 = pd.concat([df_clustered, to_enrich], axis=1, join='inner')
        df_full2 = df_full2.rename(mapper={0:'pca_0', 1:'pca_1', 2:'pca_2'}, axis='columns')
```

```
In [ ]: df_full2.head(10)
```

```
In [ ]: for c in range(0, n_):
            in_cluster = df_full2[df_full2.cluster == c]
            print("Cluster %i" % c)
            s_sz = (len(in_cluster),10)[10 < len(in_cluster)]
            print(in_cluster.sample(n=s_sz)['movie_title'])
            in_cluster.to_csv("../ProcessedData/clustering/10k/cluster_%i_dbscan.csv" % c)
            clusters_samples[c] = in_cluster
```

5.2.4 Onde estão os filmes populares?

```
In [ ]: dbscan_populares = df_full2[df_full2['id'].isin(popular_ids.index)]
```

```
In [ ]: filmsInClusterCount = pd.Series(data=dbscan_populares.groupby(['cluster']).count()['pca
```

```
In [ ]: plt.figure()
        filmsInClusterCount.plot.bar()
        plt.xlabel("cluster")
```

```
plt.grid(True)
plt.ylabel("freq. absoluta")
plt.title('distribuição dos filmes populares nos clusters')
plt.show()
```

conclsão > Os filmes poplares são mais frequentes no cluster de ruído e no cluster 0. O que indica que o algoritmo foi pouco sensível a esses filmes populares ja que a maioria deles caiu no cluster do ruído

```
In [ ]: for c in range(0, n_):
            in_cluster = dbscan_populares[dbscan_populares.cluster == c]
            if len(in_cluster) > 2:
                print("filmes populares do Cluster %i" % c)
                print(in_cluster.sample(n=2)['movie_title'])
                in_cluster.to_csv("../ProcessedData/clustering/10k/cluster_%i_kmeans.csv" % c)
                clusters_samples[c] = in_cluster
```

6 Conclusão

6.1 Na Base de 100k

Vetores de features e PCA

Os vetores de features (notas dadas por todos os usuários para o filme) realmente eram esparsos como se esperava. A nédia dos filmes recebeu 59 notas, mas a distribição do número de usuários que deu nota pra os filmes é altamente assimétrica e a moda da distribuição é 1. Por isso, o PCA reduziu bastante as dimensões do problema e 3 componentes representam quase 90% da energia total dos vetores de features. Com a dimensão reduzida, foi possível rodar os alogoritmos em tempo viável.

Os filmes populares, que foram definidos com aqueles com um grande número de notas diferentes de 0. Utilizei o box plot para determinar um limiar de 100 para esses filmes, o que faz com que 333 filmes sejam considerados populares.

Clusterização KMeans

A função de loss (somatório das distâncias ao quadrado dos pontos aos centróides de seus clusters) apresentou um "joeçho" em 10 clusters e por isso esse foi o número de clusters que foi utilizado. Os clusters obtidos pelo Kmenas são paralelos a dimensão 0 do PCA (a de maior variância) e, a exceção de uns poucos, são formados por um grande número de filmes.

O algoritmo parece distribuiu os filmes populares entre os clusters. Eles se revelaram mais frequentes nos clusters 0, 5 e 2 que são clusters com uma grande quantidade de filmes.

Clusterização DBScan

o ajuste dos hiper-parâmetros do algoritmo DBScan foi menos sistemático já que a ausência do conceito de uma função de loss que seja minimizada dificulta essa avaliação. O que se observou foi que:

- Se diminuimos o eps, mantendo-se o mesmo valor de min_samples, o grupo 0 aumenta e o grupo -1 (ruído) diminui
- Se mantemos o valor de eps fixo e aumentamos o valor de min_samples, o número de clusters diminui e o tamanho do grupo -1 (ruído) também aumenta.

O espaço de features abstrato, isto é, a transformada PCA dos vetores de features, dificultou bastante a escolha de parâmetros adequados. Por fim, observou-se que o número de pontos do conjunto de ruído é relativamente alto e o tamanho dos clusters gerados é tipicamente menor que os gerados pelo KMeans.

O algoritmo não parece sensível aos filmes populares já que a maioria deles caiu no grupo de ruído (-1).